



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y
Tecnología

Máster Universitario en Inteligencia Artificial

Sistema de accesibilidad
educativa en tiempo real
con transcripción adaptati-
va: comparativa de técnicas
sobre modelos ASR en es-
pañol

Trabajo Fin de Estudios

presentado por: [Nombre y apellidos]

Dirigido por: [Pendiente de asignación]

Ciudad: [Ciudad]

Fecha: [d de mes de 2026]

Índice de Contenidos

Resumen	v
Abstract	vi
1. Introducción	1
1.1. Motivación	1
1.2. Planteamiento del trabajo	1
1.3. Estructura del trabajo	2
2. Contexto y Estado del Arte	3
2.1. Reconocimiento automático del habla de propósito general	3
2.2. Técnicas de adaptación al dominio	3
2.3. Recursos de habla en español	4
2.3.1. El corpus objetivo	4
2.3.2. Los recursos efectivamente empleados	4
2.3.3. La calidad de la referencia como variable	5
2.4. Evaluación de sistemas de reconocimiento	5
2.4.1. La métrica habitual y sus límites	5
2.4.2. Alucinaciones	6
2.5. Subtitulado en tiempo real	6
2.6. Posicionamiento del trabajo	6
3. Identificación de Requisitos	8
3.1. Requisitos del sistema de subtitulado	8
3.1.1. Funcionales	8
3.1.2. No funcionales	8
3.2. Requisitos del procedimiento experimental	9
4. Objetivos	11
4.1. Objetivo general	11
4.2. Objetivos específicos	11
4.3. Criterios de cumplimiento	12
4.4. Alcance y exclusiones	13

5. Desarrollo del trabajo	14
5.1. Metodología experimental	14
5.1.1. Principios de diseño	14
5.1.2. Potencia estadística requerida	14
5.1.3. Corpus	15
5.2. Línea base sin adaptación	15
5.2.1. Elección del modelo	15
5.2.2. El modelo elegido y por qué no es el más rápido	16
5.3. Comparativa de técnicas de adaptación	17
5.3.1. Prompting contextual	17
5.3.2. Post-corrección con un modelo de lenguaje local	18
5.3.3. Ajuste fino con LoRA	19
5.4. El WER no basta para evaluar accesibilidad	19
5.5. Desarrollo de la aplicación	20
5.5.1. Arquitectura	20
5.5.2. Troceado del audio: latencia frente a calidad	20
5.5.3. Requisito de hardware	21
5.5.4. Robustez frente al ruido de aula	21
5.6. Incidentes metodológicos	22
6. Conclusiones y Trabajo Futuro	24
6.1. Conclusiones	24
6.1.1. Sobre las técnicas de adaptación	24
6.1.2. Sobre dónde está realmente el margen de mejora	24
6.1.3. Sobre la evaluación	25
6.1.4. Sobre la validez de las mediciones	25
6.2. Limitaciones	25
6.3. Trabajo futuro	26
Referencias	28

Índice de Ilustraciones

5.1. Calidad frente a coste y rendimientos decrecientes por tamaño de modelo.
La línea vertical marca el límite de tiempo real. Generada desde los datos
de ejecución. 16

Índice de Tablas

3.1. Requisitos funcionales del sistema de subtitulado.	8
3.2. Requisitos no funcionales del sistema de subtitulado.	9
3.3. Requisitos del procedimiento experimental.	10
4.1. Criterios de cumplimiento de los objetivos específicos.	12
5.1. Corpus empleados en la comparativa. Ninguno es aula real; la justificación de cada uno y sus limitaciones se detallan en el capítulo 2.	15
5.2. WER (%) de los modelos Whisper sin adaptar según corpus, con normalización básica. La columna Δ tildes indica cuanto baja el WER de <code>medium</code> al ignorar la acentuación: valores altos delatan referencias con tildes omitidas (R11), no mejor reconocimiento.	16
5.3. Efecto de cada técnica de adaptación sobre el WER (%), con diseño pareado. Δ negativo indica mejora. El intervalo de confianza se obtiene por bootstrap remuestreando clips; p corresponde al test de signos sobre los clips que cambian.	17
5.4. Segmentación por silencios frente a ventana fija, a latencia media equivalente.	21
5.5. Degradación frente al ruido según relación señal-ruido y tipo de ruido. . . .	22

Resumen

El alumnado con discapacidad auditiva depende de que alguien transcriba lo que se dice en clase. Este trabajo evalúa si las técnicas habituales de adaptación de modelos de reconocimiento automático del habla mejoran esa transcripción en español, y desarrolla una aplicación de subtitulado en vivo desplegable en la red de un centro. Se comparan tres técnicas sobre Whisper con diseño pareado, intervalos de confianza por remuestreo y test de signos: prompting contextual, post-corrección con un modelo de lenguaje local y ajuste fino con LoRA. Solo la última mejora de forma concluyente, con 1,23 puntos de reducción del error de palabra; la post-corrección lo empeora. El resultado principal es otro: segmentar el audio por silencios en lugar de por reloj reduce el error 7,4 puntos a igual latencia, seis veces más que la mejor técnica de adaptación. Se muestra además que el WER agregado oculta los fallos que importan en accesibilidad, y se propone una métrica complementaria que los expone.

Palabras clave: accesibilidad educativa; reconocimiento automático del habla; adaptación al dominio; subtitulado en tiempo real; evaluación de sistemas ASR.

Abstract

Students with hearing impairment depend on someone transcribing what is said in class. This work evaluates whether the usual domain adaptation techniques for automatic speech recognition improve that transcription in Spanish, and develops a live captioning application deployable on a school network. Three techniques are compared on Whisper using a paired design, bootstrap confidence intervals and sign tests: contextual prompting, post-correction with a local language model, and LoRA fine tuning. Only the last one improves conclusively, reducing word error rate by 1.23 points; post-correction makes it worse. The main finding lies elsewhere: segmenting audio at silences rather than at fixed intervals reduces error by 7.4 points at equal latency, six times more than the best adaptation technique. The work also shows that aggregate WER hides the failures that matter for accessibility, and proposes a complementary metric that exposes them.

Keywords: educational accessibility; automatic speech recognition; domain adaptation; real time captioning; ASR evaluation.

1. Introducción

1.1. Motivación

Un alumno con discapacidad auditiva que asiste a una clase magistral se enfrenta a un problema que el resto no tiene: la información llega por un canal que no puede usar. Las soluciones habituales pasan por un intérprete de lengua de signos o por un profesional que transcriba en directo, y ambas comparten la misma limitación: dependen de que haya una persona disponible, con formación específica, durante toda la sesión. En la práctica eso significa que muchas clases se quedan sin cobertura.

El reconocimiento automático del habla ha alcanzado en los últimos años una calidad que invita a plantear la alternativa. Los modelos de propósito general funcionan razonablemente bien en español sin necesidad de entrenarlos, y el equipamiento necesario para ejecutarlos ha dejado de ser exclusivo de centros de cálculo. La pregunta ya no es si la transcripción automática es viable, sino si lo es *con la calidad suficiente* para que un alumno pueda seguir una clase sin perder contenido.

Esa distinción es la que motiva este trabajo. Un sistema que acierta el noventa por ciento de las palabras suena aceptable expresado así; pero si el diez por ciento restante incluye los términos técnicos de la asignatura, los nombres propios o las negaciones, el alumno no recibe una versión ligeramente degradada de la clase: recibe una versión distinta. La métrica habitual del campo, la tasa de error de palabra, no distingue entre perder una preposición y perder un *no*.

1.2. Planteamiento del trabajo

El trabajo tiene dos núcleos que se abordan por separado y se apoyan mutuamente.

El primero es una comparativa empírica: se evalúa si las técnicas de adaptación al dominio más habituales mejoran el reconocimiento en español sobre material que se parece al de un aula. Se estudian tres: aportar al modelo un glosario de la asignatura como contexto, corregir su salida con un modelo de lenguaje, y ajustar sus pesos mediante LoRA. Cada una se mide con el mismo diseño, sobre el mismo corpus y con el mismo criterio estadístico, de modo que las cifras sean comparables entre sí.

El segundo es una aplicación de subtítulo en vivo, construida para desplegarse en

la red local de un centro: el docente emite desde su equipo y el alumnado lee desde el suyo, sin que ningún dispositivo del aula necesite capacidad de cálculo. La aplicación no es una demostración del primer núcleo; es un banco de pruebas que plantea preguntas propias, como cada cuánto trocear el audio o dónde cortarlo, que se responden con la misma metodología experimental.

La relación entre ambos resultó menos unidireccional de lo previsto. La investigación proporcionó a la aplicación criterios de diseño medidos en lugar de intuitos; pero la aplicación detectó a su vez un problema que ningún experimento de laboratorio podía ver, porque solo aparece cuando hay un micrófono y un navegador reales de por medio.

1.3. Estructura del trabajo

El capítulo 2 sitúa el trabajo respecto a la literatura y a la práctica del sector, y documenta la búsqueda de corpus, que resultó ser el condicionante principal de todo el diseño experimental. El capítulo 3 deriva los requisitos, tanto funcionales de la aplicación como metodológicos de la comparativa. El capítulo 4 enuncia los objetivos y los criterios con los que se consideran cumplidos.

El capítulo 5 contiene el grueso del trabajo: la metodología experimental, los nueve experimentos realizados con sus resultados, y el desarrollo de la aplicación. El capítulo 6 recoge las conclusiones, las limitaciones reconocidas y las líneas que quedan abiertas.

Conviene anticipar una particularidad de este trabajo: buena parte de sus aportaciones no proviene de que las técnicas estudiadas funcionaran, sino de descubrir bajo qué condiciones las mediciones que las evalúan son válidas. Varias de las conclusiones surgieron de detectar que un resultado aparentemente sólido era un artefacto del procedimiento de medida. Esos hallazgos se documentan con el mismo detalle que los resultados positivos, porque condicionan cómo deben interpretarse todos los demás.

2. Contexto y Estado del Arte

2.1. Reconocimiento automático del habla de propósito general

El punto de partida de este trabajo es Whisper (Radford y cols., 2023), un modelo codificador-decodificador entrenado sobre una cantidad masiva de audio con supervisión débil. Su relevancia para el problema planteado no está en alcanzar el mejor resultado en un banco de pruebas concreto, sino en dos propiedades prácticas: funciona en español sin necesidad de entrenamiento adicional, y es lo bastante robusto frente a condiciones de grabación variables como para plantear su uso fuera de un estudio.

El modelo procesa el audio en ventanas de treinta segundos. Esa decisión de diseño, que resulta natural para transcribir grabaciones completas, se convierte en un obstáculo cuando se pretende subtítular en directo: el sistema no puede esperar medio minuto para mostrar la primera palabra. La adaptación de un modelo pensado para procesamiento por lotes a un escenario de flujo continuo es un problema abierto (Macháček, Dabre, y Bojar, 2023), y constituye una parte sustancial del trabajo de ingeniería descrito en el capítulo 5.

2.2. Técnicas de adaptación al dominio

Cuando un modelo general se aplica a un dominio concreto, la terminología específica y el registro propio de ese dominio suelen degradar el resultado. Las estrategias para corregirlo se ordenan por coste creciente.

Condicionamiento por contexto. La más barata consiste en aportar al decodificador un texto previo que oriente sus predicciones, sin modificar el modelo. En Whisper esto se implementa mediante un prompt que actúa como transcripción anterior. Es atractiva porque no requiere entrenamiento ni datos anotados: bastaría con que el docente proporcionara el glosario de la asignatura.

Corrección posterior con un modelo de lenguaje. Una segunda vía deja intacto el reconocedor y repara su salida mediante un modelo de lenguaje, aprovechando que este dispone de conocimiento léxico y sintáctico del que el reconocedor carece. La intuición es sólida; los resultados de este trabajo la contradicen, y el capítulo 5 explica por qué.

Ajuste fino con adaptadores. La tercera modifica los pesos del modelo. El ajus-

te completo resulta inviable en equipamiento modesto, pero LoRA (Hu y cols., 2021) permite entrenar únicamente unas matrices de rango bajo insertadas en las capas de atención, reduciendo los parámetros entrenables en varios órdenes de magnitud y produciendo adaptadores de unos pocos megabytes. Es lo que hace que esta técnica sea abordable en el contexto de un trabajo como este.

2.3. Recursos de habla en español

La disponibilidad de corpus condicionó el diseño experimental más que ninguna otra decisión, hasta el punto de que conviene documentar la búsqueda y no solo su resultado.

2.3.1. El corpus objetivo

El recurso que mejor se ajusta al problema es poliMedia, el repositorio de clases grabadas de la Universitat Politècnica de València, del que el proyecto europeo transLectures transcribió manualmente más de ciento quince horas (del Agua y cols., 2014). Reúne las tres condiciones que este trabajo necesita: dominio educativo real, lengua española y transcripción verificada por personas.

No se encuentra publicado en ningún repositorio de acceso abierto. Se cursó una solicitud institucional al grupo responsable, que no obtuvo respuesta dentro del plazo de este trabajo. Esta circunstancia es la limitación de fondo de toda la parte experimental.

2.3.2. Los recursos efectivamente empleados

A falta del corpus objetivo se recurrió a sustitutos, escogidos para cubrir ejes distintos del problema en lugar de acumular horas.

VoxPopuli (Wang y cols., 2021) aporta discurso parlamentario en español peninsular. Presenta dos propiedades que resultaron decisivas: incorpora una marca que identifica las transcripciones verificadas manualmente, y anota la variedad dialectal del hablante. FLEURS (Conneau y cols., 2022) proporciona voz leída de dominio general, útil como techo de calidad; conviene señalar que su configuración en español corresponde a la variedad latinoamericana, sin equivalente peninsular. Se emplearon además dos recursos de habla espontánea en español de México procedentes de repositorios abiertos, y un conjunto de locución de medios en español peninsular.

2.3.3. La calidad de la referencia como variable

Un hallazgo de la fase de búsqueda merece mención aquí porque afecta a la interpretación de toda la literatura basada en estos recursos: la calidad de las transcripciones de referencia varía sustancialmente entre corpus abiertos, y esa variación se confunde con diferencias de rendimiento del modelo.

En los recursos de habla espontánea empleados, las referencias omiten la acentuación de forma sistemática y contienen erratas. Medido sobre ellos, entre un tercio y un cuarenta por ciento de la tasa de error atribuida al modelo corresponde en realidad a defectos de la referencia. Se observaron casos en que el sistema escribía correctamente una palabra que la transcripción de referencia recogía mal, y era penalizado por ello.

La consecuencia práctica quedó incorporada al procedimiento: antes de adoptar un corpus se audita manualmente una muestra de sus referencias. Que un recurso disponga de transcripción no implica que sirva como referencia.

2.4. Evaluación de sistemas de reconocimiento

2.4.1. La métrica habitual y sus límites

La tasa de error de palabra, definida como la distancia de edición entre referencia e hipótesis normalizada por la longitud de la referencia, es la métrica estándar del campo. Su fortaleza es la comparabilidad; su debilidad, que asigna el mismo coste a todas las palabras y a todas las operaciones de edición.

Esa limitación está documentada en la literatura reciente, que señala que la métrica opera en el plano léxico sin consideración del contexto semántico, y que trata de forma idéntica errores que destruyen la comprensión y errores irrelevantes para ella. Se han propuesto alternativas que ponderan las palabras según su contenido informativo, que penalizan de forma específica los errores sobre entidades nombradas, o que combinan la distancia de edición con señales de distancia semántica.

Este trabajo llega a la misma conclusión por vía empírica y desde un dominio concreto: los errores que perjudican a un alumno con discapacidad auditiva no son los que más pesan en la métrica. Las mediciones que lo sustentan, y los instrumentos complementarios que se proponen, se presentan en el capítulo 5.

2.4.2. Alucinaciones

Un modo de fallo específico de los modelos generativos aplicados al reconocimiento consiste en producir texto fluido y verosímil sin correspondencia con el audio. A diferencia de un error ordinario, resulta indetectable para el usuario final: la salida es gramatical y coherente con el dominio.

Para un sistema de accesibilidad esta distinción es central. Un subtítulo ausente se percibe como una carencia; uno inventado se lee como información. El trabajo incorpora por ello la detección de salidas anómalas como criterio de selección de modelo, y no solo la tasa de error.

2.5. Subtitulado en tiempo real

La literatura sobre adaptación de Whisper a escenarios de flujo continuo (Macháček y cols., 2023) y la práctica documentada del sector coinciden en varios puntos que sirvieron de referencia para el diseño de la aplicación: emplear ventanas de entre cinco y diez segundos, solaparlas para no perder las palabras que caen en la frontera, y apoyarse en detección de actividad de voz para decidir cuándo dar por terminada una intervención.

Coinciden también en desaconsejar el condicionamiento sobre la transcripción previa entre ventanas, por el riesgo de propagación de errores. Este trabajo verificó esa recomendación de forma independiente y obtuvo el mismo resultado, lo que constituye una validación externa útil de la parte experimental.

La divergencia principal respecto a la práctica habitual está en el umbral de silencio empleado para cerrar una intervención, y se discute en el capítulo 5 junto con la medición que la respalda.

2.6. Posicionamiento del trabajo

Este trabajo no propone una técnica nueva de adaptación ni un modelo nuevo. Su aportación se sitúa en tres planos.

En el plano empírico, compara tres técnicas de adaptación sobre español con un diseño y un criterio estadístico homogéneos, y contrasta su rendimiento con el de las decisiones de ingeniería del sistema; una comparación que la literatura suele tratar por separado.

En el plano metodológico, documenta las condiciones bajo las cuales esas medicio-

nes son válidas, incluyendo varios casos en que un procedimiento aparentemente correcto produce cifras verosímiles y falsas.

En el plano aplicado, construye un sistema desplegable en un centro educativo y lo emplea como banco de pruebas, del que surgieron preguntas que la parte experimental no se habría planteado.

3. Identificación de Requisitos

El trabajo tiene dos núcleos y por tanto dos conjuntos de requisitos de naturaleza distinta: los que debe cumplir la aplicación para ser útil en un aula, y los que debe cumplir el procedimiento experimental para que sus conclusiones sean válidas. Los segundos suelen quedar implícitos; aquí se enuncian porque varias decisiones del trabajo se derivan directamente de ellos.

3.1. Requisitos del sistema de subtulado

3.1.1. Funcionales

Id	Requisito
RF1	El sistema transcribe en directo la voz del docente y muestra el resultado como subtítulos.
RF2	Varios alumnos pueden visualizar simultáneamente los subtítulos desde sus propios dispositivos.
RF3	El alumnado no necesita instalar nada ni conceder permisos: basta con abrir una dirección en el navegador.
RF4	El docente puede definir, antes de comenzar, la terminología de la sesión, que se resalta visualmente en los subtítulos.
RF5	Un alumno que se incorpora una vez iniciada la clase recupera lo transcrito hasta ese momento.
RF6	Cada alumno ajusta el tamaño del texto en su propio dispositivo.
RF7	El sistema informa de la latencia con que está operando.

Tabla 3.1: Requisitos funcionales del sistema de subtulado.

El requisito RF6 no es un detalle de comodidad. El sistema se dirige a personas con una discapacidad sensorial, y no cabe suponer que quien lo desarrolla pueda fijar un tamaño de texto adecuado para todas ellas ni para todas las distancias de lectura de un aula.

3.1.2. No funcionales

RNF2 es el que determina la arquitectura. Si cada dispositivo del aula ejecutara el modelo, el sistema exigiría una unidad de cálculo por alumno y dejaría de ser desplegable. De ahí que todo el reconocimiento resida en el servidor y los clientes se limiten a visualizar.

Id	Requisito
RNF1	La latencia entre lo dicho y lo mostrado debe permitir seguir la clase. El umbral concreto se determina experimentalmente y se reporta con su valor típico y su peor caso.
RNF2	El coste de cálculo no debe crecer con el número de alumnos conectados.
RNF3	El sistema opera exclusivamente en la red local del centro.
RNF4	El puesto de emisión está protegido frente a uso no autorizado.
RNF5	El sistema funciona con equipamiento asequible para un centro educativo.
RNF6	El requisito de captación de audio debe expresarse en términos verificables, no como recomendación genérica.

Tabla 3.2: Requisitos no funcionales del sistema de subtitulado.

RNF3 se deriva de la naturaleza del material: el sistema difunde audio de aula transcrito, con voces identificables y frecuentemente de menores de edad. La restricción no puede delegarse en la configuración de red del centro, porque un reenvío de puertos mal configurado la anularía sin que nadie lo advirtiera; debe imponerla la propia aplicación.

RNF6 responde a un problema recurrente en los requisitos de este tipo de sistemas. Indicar que se necesita “un micrófono adecuado” no es verificable. La caracterización experimental frente al ruido permite sustituirlo por una condición comprobable sobre la relación señal-ruido, y con ella justificar la elección del equipo de captación.

3.2. Requisitos del procedimiento experimental

Estos requisitos no proceden del usuario sino de la naturaleza de la pregunta que el trabajo pretende responder. Se enuncian porque su incumplimiento no produce un fallo visible: produce cifras verosímiles y falsas.

RE2 merece justificación porque resulta menos evidente que los demás. Durante el trabajo se comprobó que dos ejecuciones del mismo modelo sobre el mismo corpus, diferenciadas únicamente por la estrategia de decodificación, arrojaban tasas de error que diferían en más de doce puntos. Un resultado identificado solo por modelo y corpus habría permitido comparar cifras no comparables sin que nada lo delatara.

RE6 se incorporó tras comprobar que una parte sustancial del error atribuido al modelo en determinados corpus correspondía en realidad a defectos de la transcripción de

Id	Requisito
RE1	Toda cifra publicada debe poder regenerarse a partir del código y los datos registrados junto a ella.
RE2	La identidad de un resultado incluye su configuración completa, no solo el modelo y el corpus.
RE3	El tamaño de muestra debe justificarse antes de interpretar diferencias, y las mediciones que no lo alcancen deben marcarse como no concluyentes.
RE4	Las comparaciones entre condiciones deben ser pareadas y compartir configuración.
RE5	Los datos empleados para adaptar el sistema deben ser disjuntos de los empleados para evaluarlo.
RE6	La calidad de las referencias debe auditarse antes de adoptarlas.
RE7	Ninguna cifra de la memoria se transcribe manualmente: las tablas y figuras se generan desde los datos de ejecución.

Tabla 3.3: Requisitos del procedimiento experimental.

referencia.

RE7 es una consecuencia práctica de RE1: una cifra copiada a mano deja de estar vinculada a la ejecución que la produjo en el momento en que se copia.

4. Objetivos

4.1. Objetivo general

Determinar si las técnicas de adaptación al dominio mejoran el reconocimiento automático del habla en español para su uso en accesibilidad educativa, y construir un sistema de subtitulado en vivo que permita comprobarlo en condiciones de aula.

El objetivo se formula deliberadamente como una pregunta abierta y no como la búsqueda de una mejora: un resultado negativo bien medido responde igual de bien que uno positivo, siempre que el procedimiento permita distinguir la ausencia de efecto de la incapacidad para detectarlo.

4.2. Objetivos específicos

Del núcleo investigador

1. Establecer una línea base reproducible del reconocimiento sin adaptar, sobre varios modelos y corpus, con trazabilidad completa de la configuración que produjo cada cifra.
2. Evaluar tres técnicas de adaptación (prompting contextual, post-corrección con un modelo de lenguaje local y ajuste fino con LoRA) bajo un diseño común que permita compararlas entre sí.
3. Determinar la potencia estadística necesaria para que la comparación sea capaz de detectar los efectos esperables, y verificar que el material empleado la alcanza.
4. Identificar qué modos de fallo relevantes para accesibilidad no quedan reflejados en la métrica habitual, y proponer instrumentos que los expongan.

Del núcleo aplicado

5. Construir una aplicación de subtitulado en vivo desplegable en la red local de un centro, con un emisor y múltiples receptores, en la que todo el cálculo resida en el servidor.

6. Caracterizar experimentalmente el compromiso entre latencia y calidad que impone el troceado del audio, y elegir el punto de operación con datos propios.
7. Cuantificar el margen acústico que requiere el sistema, para poder formular requisitos de despliegue verificables.
8. Mantener una frontera entre investigación y aplicación que permita incorporar la técnica ganadora al sistema desplegado sin modificarlo.

4.3. Criterios de cumplimiento

Cada objetivo se considera alcanzado bajo condiciones explícitas, fijadas antes de ejecutar los experimentos para evitar ajustarlas a los resultados obtenidos:

Obj.	Se considera cumplido si
1	Cualquier cifra publicada puede regenerarse con un solo comando, y el resultado registra el commit y el contenido exacto del corpus empleado.
2	Las tres técnicas se miden sobre el mismo corpus, con la misma decodificación y el mismo criterio de significación.
3	El tamaño de muestra se justifica con un cálculo previo, y las mediciones que no lo alcanzan se marcan como no concluyentes en lugar de interpretarse.
4	Se dispone de al menos una métrica adicional que detecte fallos invisibles al WER, con evidencia de que tales fallos existen en el material analizado.
5	Un cliente conectado a la red del centro visualiza los subtítulos sin ejecutar ningún cálculo ni requerir permisos de captura.
6	La elección del tamaño y la estrategia de segmentación se respalda con un barrido propio, no con valores tomados por convención.
7	Existe una curva de degradación frente a ruido que permita expresar el requisito de captación en términos verificables.
8	La técnica ganadora se incorpora al sistema desplegado sin modificar el código de la aplicación.

Tabla 4.1: Criterios de cumplimiento de los objetivos específicos.

4.4. Alcance y exclusiones

Quedan fuera del alcance, y se declaran aquí para evitar que se interpreten como carencias: la evaluación con usuarios reales del sistema desplegado; la traducción a otros idiomas o a lengua de signos; el reconocimiento de múltiples hablantes simultáneos; y la identificación de quién habla en cada momento. El sistema asume un único emisor, que es el escenario de la clase magistral.

5. Desarrollo del trabajo

5.1. Metodología experimental

5.1.1. Principios de diseño

Toda la comparativa descansa sobre cuatro decisiones metodológicas que se fijaron antes de ejecutar ningún experimento.

Diseño pareado. Cada técnica se evalúa sobre exactamente los mismos fragmentos de audio que su línea base, en la misma ejecución y con la misma configuración de decodificación. Esto permite comparar fragmento a fragmento en lugar de comparar dos medias, que es lo único que proporciona algo de potencia estadística con corpus de tamaño moderado.

Doble criterio de significación. Se calcula un intervalo de confianza al 95 % para la diferencia de error mediante remuestreo por bootstrap, y un test de signos sobre los fragmentos que cambian. Una diferencia se considera significativa solo si ambos coinciden. El motivo es práctico: durante el trabajo apareció un caso en que el intervalo excluía el cero por muy poco y el test de signos no lo respaldaba; interpretarlo como efecto real habría sido forzar el dato.

Remuestreo por fragmentos, no por palabras. Los errores de reconocimiento se agrupan dentro de un mismo fragmento y un mismo hablante. Tratar las palabras como observaciones independientes estrecha el intervalo de confianza de forma artificial y produce significación donde no la hay.

Trazabilidad completa. Cada resultado registra el commit del código, si el árbol de trabajo estaba limpio, y el resumen criptográfico del manifiesto de corpus empleado. La razón se explica en la sección 5.6.

5.1.2. Potencia estadística requerida

Antes de interpretar ninguna diferencia hubo que responder cuánto material hace falta para poder detectarla. Con 499 palabras de referencia, el error estándar del WER en torno al 3 % ronda 0,8 puntos, de modo que el intervalo de confianza alcanza aproximadamente $\pm 1,5$ puntos: bajo esas condiciones, tres modelos que difieren en 0,4 puntos son indistinguibles.

Para detectar diferencias del orden de 0,5 puntos, que es la escala en que se mueven las

técnicas de adaptación, hacen falta del orden de 30.000 palabras de referencia; unas tres o cuatro horas de audio transcrito. La cifra es una cota optimista, porque supone errores independientes cuando en realidad se agrupan.

Esta estimación condicionó todo lo demás: las mediciones que no la alcanzan se marcan como no concluyentes y no se interpretan, ni a favor ni en contra.

5.1.3. Corpus

El obstáculo principal del trabajo fue localizar audio educativo en español con transcripción de referencia fiable. La búsqueda y auditoría de candidatos se documenta en el capítulo 2; aquí importa el resultado: se emplearon cinco corpus de características deliberadamente distintas, resumidos en la tabla 5.1.

Corpus	Variedad	Registro	Clips
fleurs-es	Latinoamérica	Voz leída, dominio general	20
tedx-es	México	Charla expositiva espontánea	40
teleconciencia-es	México	Divulgación científica en televisión	1.200
mediaspeech-es	Peninsular	Locución de medios	40
voxpopuli-es	Peninsular	Debate parlamentario	400

Tabla 5.1: Corpus empleados en la comparativa. Ninguno es aula real; la justificación de cada uno y sus limitaciones se detallan en el capítulo 2.

Ninguno de ellos es una clase grabada. Esta es la limitación de fondo del trabajo y condiciona la validez externa de todas las conclusiones; se discute en la sección 6.2.

5.2. Línea base sin adaptación

5.2.1. Elección del modelo

Se evaluaron seis tamaños de Whisper sobre el mismo material. La figura 5.1 muestra el compromiso entre calidad y coste, y la tabla 5.2 recoge el detalle por corpus.

Dos observaciones condicionan el resto del trabajo.

La primera: en material de habla espontánea, aumentar el tamaño del modelo deja de compensar. Entre `medium` y `large-v3-turbo` la diferencia es nula, y entre `small` y `medium` apenas 1,5 puntos sobre el corpus más difícil, frente a los 3,2 que separan los mismos modelos en voz leída. El margen que queda no está en el tamaño; ese es precisamente el




Figura 5.1: Calidad frente a coste y rendimientos decrecientes por tamaño de modelo. La línea vertical marca el límite de tiempo real. Generada desde los datos de ejecución.

Corpus	Variedad	Registro	tiny	base	small	medium	large-v3-turbo
voxpathuli-es-400	?	?	—	—	—	9.63	—
fleurs-es	Latinoamérica	Leída, enciclopédica	19.44	11.42	6.61	3.21	3.41
tedx-es	México	Charla espontánea	—	—	12.13	10.22	11.12
teleconciencia-es	México	Divulgación científica	—	—	23.42	18.61	22.26
mediaspeech-es	Peninsular	Medios, locución	—	—	15.94	14.72	15.60
voxpathuli-es	Peninsular	Parlamentario	—	—	12.01	10.44	11.53

Tabla 5.2: WER (%) de los modelos Whisper sin adaptar segun corpus, con normalizacion basica. La columna Δ tildes indica cuanto baja el WER de **medium** al ignorar la acentuacion: valores altos delatan referencias con tildes omitidas (R11), no mejor reconocimiento.

supuesto que motiva estudiar la adaptación.

La segunda: lo que domina el error no es la variedad dialectal sino el registro. A registro equivalente, el español peninsular y el mexicano dan cifras casi idénticas: 10,44 % frente a 10,22 %. Lo que lleva el error del 3 % al 23 % es leer un texto frente a hablar de forma espontánea.

5.2.2. El modelo elegido y por qué no es el más rápido

La primera lectura recomendaba **large-v3-turbo**: igualaba a **medium** en tasa de error y era el doble de rápido. Esa lectura ignoraba el modo de fallo.

Contabilizando las salidas anómalas, entendidas como transcripciones con menos de un cuarto de las palabras esperadas, **turbo** produjo tres sobre 180 fragmentos y **medium**

ninguna. Y no son truncamientos inocuos: en varios fragmentos el modelo emitió una frase fluida, gramatical y plausible en el dominio que no guardaba relación con lo dicho.

Para un sistema de accesibilidad ese criterio pesa más que unas décimas de tasa de error. Un subtítulo ausente se nota; uno inventado, no: el alumno con discapacidad auditiva no tiene forma de detectarlo porque se lee perfectamente bien. Se eligió **medium**.

5.3. Comparativa de técnicas de adaptación

Técnica	Corpus	WER base	WER téc.	Δ (pp)	IC 95 %	p
Prompting contextual	tedx-es	10.15	9.96	-0.19	[-0.61, +0.00]	1.00
Prompting contextual	teleconciencia-es	18.79	19.14	+0.35	[-0.52, +1.42]	0.01
Prompting contextual	voxpathuli-es	9.99	9.60	-0.39	[-1.14, +0.45]	0.37
Prompting contextual	voxpathuli-es-400	9.51	9.14	-0.37	[-0.76, -0.05]	0.23
Post-corrección con LLM	teleconciencia-es	19.55	22.77	+3.23	[+2.66, +3.84]	0.00
Post-corrección con LLM	voxpathuli-es-400	9.63	10.81	+1.18	[+0.84, +1.54]	0.00
Post-corrección con LLM	voxpathuli-es	12.50	12.15	-0.35	[-1.69, +1.12]	1.00
Fine-tuning con LoRA	voxpathuli-es-400	9.63	8.40	-1.23	[-1.75, -0.77]	0.00

Tabla 5.3: Efecto de cada técnica de adaptación sobre el WER (%), con diseño pareado. Δ negativo indica mejora. El intervalo de confianza se obtiene por bootstrap remuestreando clips; p corresponde al test de signos sobre los clips que cambian.

5.3.1. Prompting contextual

La técnica aporta al decodificador un glosario del dominio como contexto previo. El glosario se extrae de fragmentos disjuntos de los que se evalúan; construirlo con las transcripciones de evaluación sería una fuga de información y cualquier mejora medida sería falsa.

El resultado no es concluyente, y lo interesante es que no lo es de dos maneras incompatibles: sobre el corpus mexicano el efecto es de +0,35 puntos y sobre el peninsular de -0,37. En ambos casos los dos criterios estadísticos discrepan entre sí. Un efecto cuyo signo se invierte entre corpus y cuyas pruebas no coinciden no es un efecto pequeño: es la firma de la ausencia de efecto.

La métrica de terminología matiza esa conclusión. Sobre el corpus grande, el prompting aumenta la cobertura de términos del glosario en 1,42 puntos mientras reduce su precisión

en 1,04: recupera términos que antes se perdían, y a cambio empieza a introducirlos donde no los hay. El desglose de errores lo confirma desde el otro lado, con 66 sustituciones menos pero 43 inserciones y 74 omisiones más. El modelo acierta más veces *qué* palabra es, y falla más veces *si* la palabra estaba.

5.3.2. Post-corrección con un modelo de lenguaje local

Un modelo de lenguaje corrige la transcripción ya producida. La salida del reconocedor queda fija, de modo que la única variable es la corrección.

La técnica degrada de forma significativa, y el resultado se replicó sobre dos corpus con características opuestas: +3,23 puntos sobre referencias con erratas y +1,18 sobre referencias verificadas manualmente. La diferencia de magnitud entre ambos es en sí misma informativa: buena parte del efecto medido inicialmente era un artefacto de la calidad de la referencia, y la cifra defendible es la del corpus limpio.

El mecanismo se observa directamente en las transcripciones. El modelo sustituye palabras por sinónimos más precisos, expande siglas, corrige la gramática del hablante y completa lo que interpreta como intención:

`cirugía → quirófano`

`Instituto de Tecnología de la UNAM → Universidad Nacional Autónoma
de México (UNAM)`

`atiendan a como un tipo terapia → atiendan cómo un tipo de terapia`

Cada una de esas ediciones mejora el texto como pieza escrita y lo empeora como transcripción; son objetivos en conflicto, y un modelo entrenado para generar lenguaje natural optimiza el primero.

El caso más ilustrativo es otro: en un fragmento, el corrector sustituyó el nombre de una persona por el nombre de una enfermedad, quedándose con el tema del programa. El resultado es fluido, gramatical y completamente falso.

Conviene declarar una limitación de este resultado. La primera versión de las instrucciones dadas al corrector era puramente prohibitiva, y con ella la técnica quedó inerte: ningún fragmento modificado a nivel de palabra, y errores evidentes sin corregir. Añadir ejemplos de qué sí debía corregirse la activó. El experimento mide, por tanto, una implementación concreta y no la técnica en abstracto.

5.3.3. Ajuste fino con LoRA

Es la única de las tres que modifica los pesos del modelo, y la única que mejora de forma concluyente: 1,23 puntos de reducción del error, con intervalo de confianza $[-1,75, -0,77]$ y ambos criterios de acuerdo. El entrenamiento empleó 1.500 fragmentos (4,64 horas) durante 15,8 minutos, y produjo un adaptador de 18,9 MB frente a los 3 GB del modelo completo.

La partición de entrenamiento y la de evaluación provienen de divisiones oficiales distintas del mismo corpus, de modo que la separación no depende de un reparto propio.

El resultado exige un matiz. La caída del error sobre contenido crítico, de 17,52 % a 6,12 %, procede casi toda de los numerales, y el motivo se ve contando dígitos: la referencia escribe los números en letra y el modelo base los escribía en cifra. El ajuste fino aprendió esa convención de transcripción. Es adaptación real, pero de estilo y no de reconocimiento acústico. Un fragmento lo ilustra: donde la referencia dice **uno seiscientos ochenta y seis**, el modelo base escribió **1 686** y el ajustado **cero cero seis**; acertó el formato y falló el número, y ambas métricas lo premiaron. Descontando los numerales, la mejora sobre contenido crítico es real pero modesta: de 7,7 % a 6,2 %.

5.4. El WER no basta para evaluar accesibilidad

Cuatro observaciones independientes, obtenidas a lo largo del trabajo, apuntan a la misma conclusión: la métrica habitual del campo oculta precisamente los fallos que perjudican al usuario final.

Contenido crítico. Sobre el corpus grande, con una tasa de error de palabra del 18,61 %, que suena aceptable, el sistema pierde o altera el 28 % de las negaciones e introduce trece que nadie pronunció. Perder una preposición se reconstruye por contexto; perder un *no* invierte la frase. El WER cuenta ambos errores igual.

Alucinaciones fluidas. Los modelos producen ocasionalmente texto verosímil y falso en lugar de fallar de forma visible. Al tratarse de salidas gramaticales y coherentes con el dominio, ni el WER agregado ni el usuario final las detectan.

Terminología. El prompting contextual no mueve el WER pero sí recupera términos del glosario. Sin una métrica específica, la técnica habría parecido completamente inocua cuando en realidad tiene un efecto dirigido.

Duplicación por solapamiento. Un defecto de implementación que multiplicaba

texto en las fronteras entre ventanas elevaba el WER por encima del 100%, pero pasó inadvertido en las pruebas automáticas y solo se detectó al leer una transcripción real.

De estas observaciones surgieron dos instrumentos complementarios: una métrica de cobertura y precisión sobre la terminología del dominio, y otra que contabiliza los errores sobre negaciones, numerales y cuantificadores, es decir, sobre las unidades cuya alteración cambia el significado y no solo la forma.

5.5. Desarrollo de la aplicación

5.5.1. Arquitectura

El sistema separa estrictamente el núcleo investigador del aplicado: la aplicación depende de una interfaz de reconocimiento y no del código de los experimentos. Esa frontera permitió incorporar el adaptador ganador al sistema desplegado sin modificar una sola línea de la aplicación.

La topología es de un emisor y múltiples receptores. El docente captura desde su equipo; el alumnado únicamente visualiza. Todo el reconocimiento ocurre una vez en el servidor, con independencia del número de clientes conectados: un diseño donde cada cliente transcribiera exigiría una unidad de cálculo por alumno, lo que contradice el objetivo de que un centro pueda desplegarlo.

El acceso queda restringido a la red local por la propia aplicación, que rechaza cualquier conexión ajena a un rango privado. Se difunde audio de aula con voces identificables; la restricción no puede depender de que nadie configure mal un reenvío de puertos.

5.5.2. Troceado del audio: latencia frente a calidad

El subtítulo en vivo no puede esperar a que termine la intervención: hay que trocear. La pregunta es cuánto cuesta cada segundo de latencia que se ahorra.

Un barrido de tamaños de ventana mostró que trocear cada N segundos degrada de forma sustancial: con ventanas de tres segundos el error casi se duplica respecto a transcribir el fragmento completo. El motivo son los cortes arbitrarios, que caen en mitad de palabra o de sintagma justo donde el modelo necesita contexto.

Esa hipótesis se contrastó cortando en los silencios en lugar de por reloj. Los resultados aparecen en la tabla 5.4.

Estrategia	WER	Duración media	p95
Ventana fija, tope 3 s	19,85 %	2,68 s	3,00 s
Silencios, tope 8 s	12,48 %	2,93 s	5,92 s
Sin trocear (referencia)	10,44 %	—	—

Tabla 5.4: Segmentación por silencios frente a ventana fija, a latencia media equivalente.

A latencia media prácticamente idéntica, segmentar por silencios reduce el error 7,4 puntos y se queda a dos del techo que marca transcribir sin trocear. El mecanismo se ve en las duraciones: con tope de ocho segundos, la segmentación por pausas produce segmentos de 2,9 segundos de media porque el tope casi nunca se alcanza. El resultado son segmentos cortos y completos, en lugar de cortos y partidos.

El precio es la previsibilidad: el percentil 95 pasa de 3,00 a 5,92 segundos. La latencia media mejora, pero el peor caso empeora; en accesibilidad esa distinción importa y ambas cifras deben reportarse.

Se comprobó además si arrastrar la transcripción anterior como contexto entre ventanas mejoraba los cortes. No aporta: el efecto es de +0,14 puntos con ventana fija y +0,61 con segmentación por silencios. La explicación encaja con lo anterior: cuando los cortes caen en pausas, cada segmento ya es una unidad coherente, de modo que el contexto no añade información que falte pero sí arrastra los errores del segmento previo.

5.5.3. Requisito de hardware

Ejecutar el reconocimiento en unidad de procesamiento gráfico no es una comodidad sino un requisito: el modelo elegido alcanza 8,1 veces la velocidad del audio en GPU y solo 1,6 en procesador convencional. Descontado el troceado, esa segunda cifra no llega a tiempo real.

5.5.4. Robustez frente al ruido de aula

Se caracterizó la degradación mediante ruido añadido de dos tipos: blanco, estacionario, y murmullo sintetizado superponiendo voces del propio corpus. Los resultados aparecen en la tabla 5.5.

Hasta 15 dB la degradación es despreciable, lo que sitúa un micrófono de solapa corriente en zona segura y permite formular el requisito de captación en términos concretos. Pero el fallo no es gradual: entre 5 y 0 dB con murmullo el error se triplica, mientras que

Relación señal-ruido	Ruido blanco	Murmullo
Audio limpio	10,44 %	10,44 %
20 dB	10,50 %	11,66 %
15 dB	10,57 %	11,19 %
10 dB	13,23 %	12,41 %
5 dB	13,98 %	14,26 %
0 dB	16,85 %	36,02 %

Tabla 5.5: Degradación frente al ruido según relación señal-ruido y tipo de ruido.

el ruido blanco al mismo nivel apenas lo altera. La diferencia confirma el mecanismo: lo que arruina el reconocimiento no es la energía del ruido sino que comparta espectro con la voz. Seis voces de fondo enmascaran lo que un ventilador no, y por eso los supresores de ruido convencionales, diseñados para ruido estacionario, no resuelven el problema del aula.

5.6. Incidentes metodológicos

Varios de los resultados anteriores estuvieron a punto de ser erróneos. Se documentan porque comparten una característica que los hace peligrosos: en todos los casos el sistema seguía funcionando y produciendo cifras verosímiles.

La configuración de decodificación como factor de confusión. Con decodificación voraz, uno de los modelos truncaba seis de cada cuarenta fragmentos y llegaba a emitir frases plausibles del dominio en lugar del contenido real; su tasa de error subía de 11,5 % a 24,2 %. Comparar técnicas sin fijar esta configuración habría medido artefactos de decodificación en lugar del efecto de la adaptación. Desde entonces, la decodificación forma parte del nombre de cada fichero de resultados.

Sobrescritura del corpus. Al ampliar un corpus de 40 a 1.200 fragmentos se sobrescribió su manifiesto; los resultados anteriores seguían apuntando a un fichero cuyo contenido ya era otro, y nada lo delataba. La corrección fue doble: registrar el resumen criptográfico del manifiesto en cada resultado, para detectar la discrepancia, y permitir que varias muestras de la misma fuente convivan, para prevenirla.

Un entrenamiento roto que no daba error. El primer ajuste con LoRA terminó correctamente, guardó su adaptador y produjo métricas evaluables, con la función de pérdida estancada en 6,87 y subiendo entre épocas. La causa era que el preparador de

lotes descartaba un identificador de token equivocado, de modo que el decodificador recibía duplicado el marcador de inicio. Corregido, la pérdida cayó a 0,21. De no haberse detectado, la evaluación habría mostrado que el ajuste fino destroza el modelo, con intervalo estrecho y significación respaldando un artefacto.

Ajustar sobre referencias defectuosas. Uno de los corpus disponibles omite las tildes de forma sistemática. Entrenar sobre él habría enseñado al modelo a no acentuar y, medido contra esas mismas referencias, la tasa de error *habría mejorado*: se habría optimizado hacia el error con la métrica dando la razón.

Un preprocesado que anula la segmentación. Al probar la aplicación con micrófono real, casi todos los segmentos se cerraban por agotar el tope en lugar de por pausa. La causa no estaba en el algoritmo sino en el control automático de ganancia del navegador: al callar el hablante sube la ganancia, amplifica el ruido de fondo y la energía nunca descende lo suficiente. Es un efecto que ningún experimento sobre audio grabado podía detectar, porque solo existe cuando hay un micrófono y un navegador de por medio.

Este último incidente ilustra la relación entre los dos núcleos del trabajo mejor que cualquier argumento: la investigación proporcionó a la aplicación su criterio de diseño, y la aplicación descubrió una condición sin la cual ese criterio no se cumple.

6. Conclusiones y Trabajo Futuro

6.1. Conclusiones

6.1.1. Sobre las técnicas de adaptación

De las tres técnicas evaluadas, solo mejora la que modifica los pesos del modelo. El ajuste fino con LoRA reduce el error 1,23 puntos con ambos criterios estadísticos de acuerdo; el prompting contextual no produce efecto detectable, con signo distinto en cada corpus y pruebas que discrepan entre sí; y la post-corrección con un modelo de lenguaje local lo empeora de forma significativa y replicada.

La conclusión sobre la post-corrección merece detenerse, porque contradice la intuición del campo. Un modelo de lenguaje debería poder reparar errores de reconocimiento usando el contexto, y sin embargo degrada. El mecanismo observado explica por qué: el corrector optimiza la calidad del texto como pieza escrita, sustituyendo palabras por sinónimos más precisos y corrigiendo la gramática del hablante, mientras que una transcripción debe reflejar lo dicho. Son objetivos en conflicto, y el modelo optimiza el que le corresponde por entrenamiento.

Sobre LoRA cabe un matiz que conviene no omitir: buena parte de su mejora consiste en aprender la convención de escritura del corpus de ajuste, no en reconocer mejor el audio. Descontado ese efecto, la ganancia sigue existiendo pero es modesta.

6.1.2. Sobre dónde está realmente el margen de mejora

El resultado más relevante del trabajo no procede de la comparativa de técnicas sino de su comparación con las decisiones de ingeniería del sistema. Segmentar el audio por silencios en lugar de por reloj reduce el error 7,4 puntos a igual latencia media; seis veces más que la mejor de las técnicas de adaptación, y a coste de cómputo prácticamente nulo.

Esto invierte la premisa de la que partía el trabajo. Se asumía que el margen estaba en adaptar el modelo al dominio educativo; los datos indican que, con los modelos actuales, el margen está en cómo se le entrega el audio. Un sistema de subtítulo en vivo que trocee mal desperdicia más calidad de la que cualquier técnica de adaptación puede recuperar.

6.1.3. Sobre la evaluación

La tasa de error de palabra es insuficiente para valorar un sistema de accesibilidad, y el trabajo aporta cuatro evidencias independientes de ello. La más contundente: con un 18,61 % de error, cifra que suena aceptable, el sistema pierde o altera el 28 % de las negaciones e introduce trece que nadie pronunció. Un alumno con discapacidad auditiva lee entonces lo contrario de lo explicado, sin ninguna señal de que algo falla.

De ahí se derivan dos instrumentos que se proponen como complemento: una métrica de cobertura y precisión sobre la terminología del dominio, y otra que contabiliza los errores sobre negaciones, numerales y cuantificadores. Ambas detectan efectos que el WER agregado no muestra, y en un caso concreto invierten la valoración de una técnica.

6.1.4. Sobre la validez de las mediciones

Cinco incidentes documentados en la sección 5.6 comparten una característica: en todos ellos el sistema seguía funcionando y produciendo cifras verosímiles. Ninguno se manifestó como un error.

La conclusión práctica es que un procedimiento experimental en este campo necesita comprobaciones que no forman parte del procedimiento habitual: verificar que la función de pérdida esté en el rango esperado antes de evaluar un modelo ajustado; auditar a mano una muestra de las referencias antes de adoptar un corpus; incorporar la configuración de decodificación a la identidad del resultado; y registrar el contenido exacto del corpus empleado, no solo su nombre.

6.2. Limitaciones

Ninguno de los corpus es una clase real. Es la limitación de fondo. Los materiales empleados se aproximan al registro de una clase magistral, pero ninguno lo es. Las conclusiones sobre adaptación al dominio educativo son, en rigor, conclusiones sobre adaptación a los dominios sustitutos disponibles. El corpus objetivo, un repositorio universitario con transcripciones manuales, requiere una solicitud institucional que quedó cursada sin resolución dentro del plazo de este trabajo.

Los resultados miden implementaciones, no técnicas. Se hizo evidente con la post-corrección: una primera versión de las instrucciones dejaba la técnica inerte, y otra la

activaba. Un prompt distinto, un modelo mayor o un ajuste de hiperparámetros podrían alterar las conclusiones.

El detector de actividad de voz es de energía. Un detector entrenado sería más robusto frente al ruido de aula, y la práctica del sector indica que la combinación de ambos reduce sustancialmente las falsas activaciones. La medición realizada justifica introducirlo, pero no se ha implementado.

El ruido se añadió de forma sintética. Falta la reverberación, que es un factor independiente y posiblemente más dañino que el ruido aditivo en un aula real.

La aplicación no se ha evaluado con usuarios. Se ha verificado su funcionamiento técnico y se ha medido su latencia, pero no se ha comprobado si el resultado es útil para quien debe leerlo.

El sistema depende de un único servidor. La difusión se resuelve en memoria, lo que ata el despliegue a un proceso. Escalar a varios exigiría una infraestructura adicional; para un aula no aplica, pero condiciona cualquier extensión a nivel de centro.

6.3. Trabajo futuro

Corpus educativo real. Es la continuación prioritaria: repetir la comparativa sobre clases grabadas convertiría las conclusiones actuales, obtenidas sobre dominios sustitutos, en conclusiones sobre el dominio objetivo.

Detección de actividad de voz entrenada. La segmentación resultó ser la palanca más eficaz del sistema, y actualmente se apoya en el método más simple posible. Mejorarla es la vía con mayor rendimiento esperable por unidad de esfuerzo.

Glosario procedente del material docente. La extracción automática por frecuencia produce vocabulario corriente que el modelo ya reconoce. Un glosario elaborado a partir del temario o las transparencias tendría el contenido que la técnica necesita, y permitiría reevaluar el prompting en condiciones justas.

Métricas de comprensión. Las métricas propuestas miden la supervivencia de unidades léxicas concretas. El paso siguiente sería medir si el alumno entiende lo mismo leyendo la transcripción que escuchando la clase, lo que exige evaluación con personas.

Implementaciones optimizadas para inferencia. Existen variantes del modelo significativamente más rápidas que la empleada, cuyo soporte para la plataforma de cálculo utilizada en este trabajo era limitado. Su viabilidad debería reevaluarse, porque el margen

de latencia condiciona directamente la usabilidad en aula.

Referencias

- Conneau, A., Ma, M., Khanuja, S., Zhang, Y., Axelrod, V., Dalmia, S., . . . Bapna, A. (2022). FLEURS: Few-shot learning evaluation of universal representations of speech. *arXiv preprint arXiv:2205.12446*.
- del Agua, M. A., Giménez, A., Serrano, N., Andrés-Ferrer, J., Civera, J., Sanchis, A., y Juan, A. (2014). The transLectures-UPV toolkit. En *Advances in speech and language technologies for iberian languages (iberspeech)* (Vol. 8854). Springer. (Describe el corpus poliMedia, con mas de 115 horas de clases en espanol transcritas manualmente)
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., . . . Chen, W. (2021). LoRA: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*.
- Macháček, D., Dabre, R., y Bojar, O. (2023). Turning whisper into real-time transcription system. *arXiv preprint arXiv:2307.14743*.
- Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., y Sutskever, I. (2023). Robust speech recognition via large-scale weak supervision. En *Proceedings of the 40th international conference on machine learning* (Vol. 202). (Preprint disponible en arXiv:2212.04356)
- Wang, C., Rivière, M., Lee, A., Wu, A., Talnikar, C., Haziza, D., . . . Dupoux, E. (2021). VoxPopuli: A large-scale multilingual speech corpus for representation learning, semi-supervised learning and interpretation. En *Proceedings of the 59th annual meeting of the association for computational linguistics and the 11th international joint conference on natural language processing*. Association for Computational Linguistics.